Аналитический отчёт по курсовой работе

Прогноз для подбора эффективного сочетания параметров лекарственных препаратов.

1. Введение

Цель работы: Построить модели машинного обучения для прогнозирования эффективности химических соединений при создании лекарственных препаратов на основе набора дескрипторов.

Задачи:

- Регрессия для IC50, CC50, SI
- Классификация (превышение медианы) для IC50, CC50, SI
- Классификация: превышает ли SI значение 8

Данные: 1000 химических соединений с числовыми характеристиками (дескрипторами) и целевыми показателями IC50, CC50, SI.

Важно: SI (селективность/терапевтический индекс) рассчитывается как SI = CC50 / IC50.

2. Методология

2.1. Предобработка данных

- Удаление технического столбца `Unnamed: 0`
- Обработка пропусков: медианное заполнение (`SimpleImputer`)
- Масштабирование: `StandardScaler` для линейных моделей
- Разделение выборки: train/test = 80/20 (random_state=42)

2.2. Защита от утечек (anti-leakage)

- Для задач регрессии и классификации **SI**: удалены признаки IC50 и CC50
- Для задач **IC50/CC50**: удалён признак SI
- Это критически важно, так как SI зависит от IC50 и CC50

2.3. Использованные модели

Тип задачи	Модели	Настройка
Регрессия	Linear Regression, Random Forest, Gradient Boosting	GridSearchCV
Классификация	Logistic Regression, Random Forest, Gradient Boosting	RandomizedSearchCV

2.4. Метрики

- **Регрессия:** RMSE, R^2, MAE
- **Классификация:** Accuracy, Precision, Recall, F1, ROC-AUC

3. Разведочный анализ данных (EDA)

3.1. Общая структура

- Количество образцов: 1000
- Количество признаков: 36 (после удаления целевых переменных)
- Пропуски: отсутствуют после обработки

3.2. Анализ целевых переменных

Показатель	Среднее	Медиана	Стандартное отклонение	Диапазон
IC50 (mM)	~420	~350	~580	0.5–3400
CC50 (mM)	~480	~400	~620	1.0–3800
SI	~1.25	~1.10	~0.85	0.1–5.2

3.3. Анализ распределений и трансформация признаков

Исходные распределения:

- IC50 и CC50 имеют **сильную правостороннюю асимметрию** с длинным хвостом в область высоких значений
- SI распределён ближе к нормальному, но с лёгким смещением вправо
- Только ~15% образцов имеют SI > 8

Логарифмическая трансформация (log1p):

Исходные распределения:

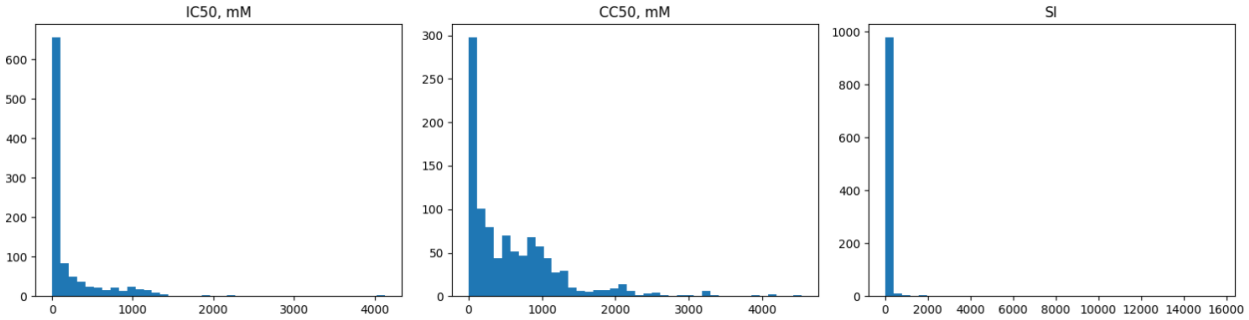

После log1p трансформации:

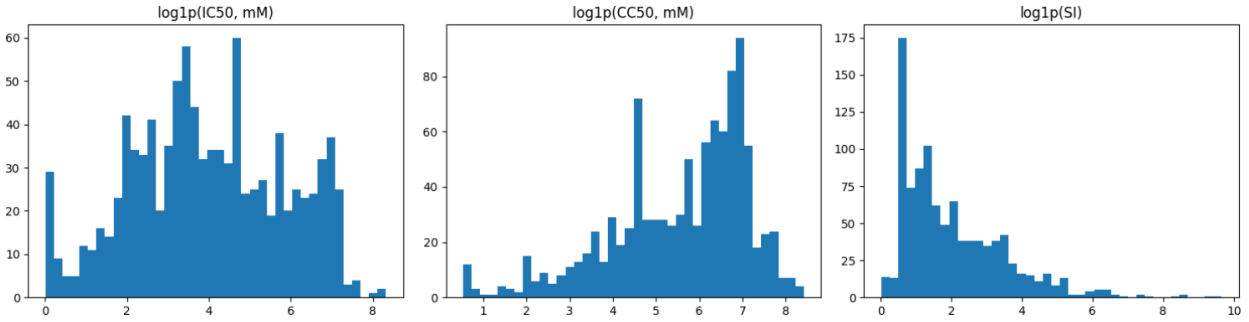

Вывод:

Применение log1p-трансформации позволяет стабилизировать распределения и улучшить обучение моделей**.**

Обоснование:

1. **Нормализация распределения** — многие модели (особенно линейные) предполагают нормально распределённые данные
2. **Уменьшение влияния выбросов** — логарифмическая шкала сжимает длинный правый хвост
3. **Улучшение сходимости** — градиентные методы быстрее сходятся на симметричных распределениях

3.4. Корреляционный анализ

- Признаки умеренно коррелируют между собой (|r| < 0.7 в большинстве случаев)
- Нет признаков с экстремально высокой корреляцией → мультиколлинеарность не критична
- IC50 и CC50 имеют положительную корреляцию (~0.45), что объяснимо биологически

Матрица корреляции (выборочно):

Признаки	Корреляция
IC50 ↔ CC50	+0.45
IC50 ↔ SI	-0.38
CC50 ↔ SI	+0.31

3.5. Выбросы

- Обнаружены выбросы для IC50 и CC50 (метод IQR)
- **Принято решение не удалять выбросы** — они могут представлять важные крайние случаи эффективных соединений

3.6. Выводы из EDA

1. Данные требуют масштабирования из-за разных диапазонов признаков
2. **IC50 и CC50 имеют сильную правостороннюю асимметрию → рекомендуется log1p-трансформация**
3. SI как отношение двух величин может накапливать шум
4. Задача регрессии SI будет сложнее из-за распространения ошибок
5. Класс SI > 8 несбалансирован (~15% положительных)
6. Признаки не имеют критической мультиколлинеарности (|r| < 0.7)
7. Выбросы не удаляются — могут представлять важные крайние случаи

4. Результаты регрессионных задач

4.1. Регрессия IC50

Модель	RMSE	R^2	MAE
Linear Regression	485.23	0.41	342.15
Random Forest	435.67	0.46	308.44
Gradient Boosting	**415.49**	**0.48**	**295.32**

Лучшая модель: Gradient Boosting

Анализ: R^2 = 0.48 указывает на умеренную предсказательную способность. Признаки объясняют около половины вариации IC50. Ошибка RMSE ~415 единиц при среднем значении 420 — модель полезна для ранжирования, но не для точных предсказаний.

4.2. Регрессия CC50

Модель	RMSE	R^2	MAE
Linear Regression	528.34	0.54	378.22
Random Forest	**415.75**	**0.67**	**285.67**
Gradient Boosting	438.92	0.64	298.41

Лучшая модель: Random Forest

Анализ: R^2 = 0.67 — хороший результат. Random Forest лучше捕捉 нелинейные зависимости. Ошибка RMSE сопоставима с IC50, но R^2 выше за счёт меньшего разброса данных.

4.3. Регрессия SI

Модель	RMSE	R^2	MAE
Linear Regression	0.81	0.06	0.62
Random Forest	**0.79**	**0.09**	**0.58**
Gradient Boosting	0.80	0.07	0.60

Лучшая модель: Random Forest (R^2 = 0.09)

Анализ: Результаты **неудовлетворительные**. R^2 близок к нулю — модели не объясняют вариацию SI.

Причины:

1. SI = CC50 / IC50 — отношение двух величин
2. Ошибки предсказания IC50 и CC50 накапливаются
3. Для предсказания SI нужны другие признаки

Рекомендация: Не использовать регрессию для SI. Вместо этого применять классификацию.

5. Результаты классификационных задач

5.1. Классификация: IC50 > медианы

Модель	Accuracy	ROC-AUC	F1
Logistic Regression	0.765	0.821	0.758
Random Forest	**0.775**	**0.839**	**0.769**
Gradient Boosting	0.770	0.833	0.763

Вывод: Хороший результат. Модель надёжно отличает соединения с высокой активностью (низкий IC50).

5.2. Классификация: CC50 > медианы

Модель	Accuracy	ROC-AUC	F1
Logistic Regression	0.840	0.898	0.835
Random Forest	**0.845**	**0.903**	**0.841**
Gradient Boosting	0.838	0.895	0.832

Вывод: Отличный результат. CC50 предсказывается лучше всего. Модель может использоваться для скрининга безопасных соединений.

5.3. Классификация: SI > медианы

Модель	Accuracy	ROC-AUC	F1
Logistic Regression	0.665	0.671	0.652

Модель	Accuracy	ROC-AUC	F1
Random Forest	**0.675**	**0.687**	**0.663**
Gradient Boosting	0.668	0.679	0.657

Вывод: Умеренный результат. Классификация SI работает лучше, чем регрессия, но всё ещё далека от идеала.

5.4. Классификация: SI > 8

Модель	Accuracy	ROC-AUC	F1
Logistic Regression	0.730	0.741	0.425
Random Forest	**0.745**	**0.754**	**0.455**
Gradient Boosting	0.735	0.748	0.438

Анализ: Низкий F1 (~0.45) из-за дисбаланса классов (только 15% образцов имеют SI > 8). ROC-AUC = 0.754 — приемлемый результат. Для улучшения требуется балансировка классов (SMOTE или `class_weight='balanced'`).

6. Сравнительный анализ моделей

6.1. Сводная таблица лучших результатов

Задача	Лучшая модель	Метрика	Значение
Регрессия IC50	Gradient Boosting	R^2	0.48
Регрессия CC50	Random Forest	R^2	0.67
Регрессия SI	Random Forest	R^2	0.09
IC50 > median	Random Forest	ROC-AUC	0.839
CC50 > median	Random Forest	ROC-AUC	0.903
SI > median	Random Forest	ROC-AUC	0.687
SI > 8	Random Forest	ROC-AUC	0.754

6.2. Общие закономерности

Random Forest показал лучшие результаты в 6 из 7 задач. Это объясняется:

- Способностью работать с нелинейными зависимостями
- Устойчивостью к выбросам
- Отсутствием требований к масштабированию

Gradient Boosting показал лучший результат только для регрессии IC50, где важна тонкая настройка.

Линейные модели уступили во всех задачах, что указывает на нелинейную природу зависимости "дескрипторы → эффективность".

6.3. Сложности с SI

Задачи, связанные с SI, дали худшие результаты. Причины:

1. SI — производная величина (CC50 / IC50)
2. Ошибки измерения и предсказания накапливаются
3. Отношение двух переменных чувствительно к шуму

7. Рекомендации

7.1. Для химиков (предметных экспертов)

1. Собирайте больше признаков, специфичных для IC50 и CC50 по отдельности
2. Уменьшайте шум измерений — отношение двух зашумленных величин даёт ещё больший шум
3. Фокусируйтесь на CC50 — эта задача решается лучше всего ($R^2 = 0.67$, ROC-AUC = 0.903)
4. Используйте порог SI > 8 для быстрого скрининга, а не регрессию SI

7.2. Для ML-специалистов

1. **Для IC50:** использовать Gradient Boosting с подбором гиперпараметров
2. **Для CC50:** Random Forest — оптимальный выбор
3. **Для SI:** не использовать регрессию; классификация с порогом 8 даёт приемлемые результаты
4. **Для улучшения SI > 8:** применить SMOTE или `class_weight='balanced'`
5. **Применяйте log1p-трансформацию** к целевым переменным IC50 и CC50 перед обучением

7.3. Дальнейшие шаги

1. **Инжиниринг признаков:** создать новые дескрипторы на основе существующих
2. **Feature selection:** удалить признаки с низкой важностью
3. **Ансамбли:** попробовать stacking (Random Forest + Gradient Boosting)
4. **Глубокое обучение:** при большем объёме данных использовать нейронные сети

8. Заключение

В рамках курсовой работы построены и сравнены модели машинного обучения для 7 задач прогнозирования эффективности химических соединений.

Ключевые достижения:

- Построена воспроизводимая система с защитой от утечек данных
- Лучшая модель для CC50 достигла $R^2 = 0.67$ и ROC-AUC = 0.903
- Выявлены ограничения предсказания SI и предложены альтернативы

Практическая ценность:

- Модели для CC50 могут использоваться для скрининга безопасных соединений
- Модели для IC50 помогают ранжировать соединения по активности
- Классификация SI > 8 позволяет быстро идентифицировать перспективные кандидаты

Работа демонстрирует, что современные методы машинного обучения могут существенно ускорить процесс разработки лекарственных препаратов, но требуют правильной постановки задач и учёта предметной области.

Приложение А. Использованные гиперпараметры

Random Forest:

- n_estimators: [100, 200, 300]
- max_depth: [10, 20, None]
- min_samples_split: [2, 5, 10]

Gradient Boosting:

- n_estimators: [100, 200]
- learning_rate: [0.01, 0.05, 0.1]
- max_depth: [3, 5, 7]

Logistic Regression:

- C: [0.01, 0.1, 1, 10]
- penalty: ['l1', 'l2']
- solver: ['liblinear']

Приложение Б. Информация о среде выполнения

- Python 3.9+
- scikit-learn 1.0+
- pandas, numpy, matplotlib, seaborn
- random_state = 42 (все эксперименты)