Финальный аналитический отчет по проекту классического машинного обучения

Прогнозирование IC50, CC50 и SI по молекулярным дескрипторам

Использованные материалы

Отчет подготовлен на основе исходного набора данных, финальных таблиц результатов моделирования и кода, отвечающего за воспроизводимую подготовку признаков:

- results/regression_ic50/model_comparison.csv;
- results/regression_cc50/model_comparison.csv;
- results/regression_si/model_comparison.csv;
- results/classification_*/model_comparison.csv;
- eda.ipynb;
- summary.md;
- classification_*.py;
- regression_*.py;
- ml_common.py.

Иллюстративные графики и диагностические визуализации описаны в разделе 8 и воспроизводятся в eda.ipynb.

---

1. Постановка задачи

Цель работы - сравнить классические модели машинного обучения для прогнозирования биологических конечных показателей по молекулярным дескрипторам.

Рассматривались семь задач:

1. регрессия IC50, mM;
2. регрессия CC50, mM;
3. регрессия SI;
4. классификация IC50 > median;
5. классификация CC50 > median;
6. классификация SI > median;
7. классификация SI > 8.

Для всех задач итоговая постановка использует только молекулярные дескрипторы: модель получает признаки, доступные до эксперимента. Колонки с конечными показателями и их производные исключаются из матрицы признаков.

2. Описание данных

2.1 Размер выборки и признаки

Датасет загружается из стабильного пути:

data/Данные_для_курсовой_Классическое_MO.xlsx

После удаления технического индекса Unnamed: 0 данные содержат:

- **1001 объект**;
- **213 колонок**;
- 3 колонки конечных показателей: IC50, mM, CC50, mM, SI;
- около 210 числовых молекулярных дескрипторов.

Загрузка централизована в ml_common.py, поэтому все эксперименты используют один и тот же источник данных и единые правила предотвращения утечки целевой переменной.

2.2 Пропуски

EDA показывает, что пропусков немного: **36 пропущенных значений** в ограниченном наборе колонок. Массовой деградации качества данных нет. Поэтому выбран консервативный подход:

- строки не удаляются;
- для моделей применяется SimpleImputer(strategy="median");
- медианная импутация предпочтительна из-за асимметрии распределений и выбросов.

2.3 Распределения целевых переменных

Целевые переменные имеют выраженную правостороннюю асимметрию:

Target	Skewness	Интерпретация
IC50, mM	~3.67	правый хвост, часть соединений имеет крупные значения
CC50, mM	~1.97	асимметрия умереннее, чем у IC50 и SI
SI	~18.01	самый тяжелый хвост, так как SI = CC50 / IC50

В eda.ipynb представлены графики:

- гистограммы с KDE для IC50, CC50, SI;
- сравнение распределений **до** и **после** log1p;

- таблица skewness до/после log1p.

log1p заметно сжимает правые хвосты и делает распределения ближе к симметричным. Логарифмы целевых переменных используются только для исследовательского анализа или как возможная трансформация целевой переменной; они не используются как признаки.

2.4 Выбросы

По IQR-критерию доля выбросов для target-переменных:

Target	Доля IQR-выбросов
IC50, mM	~14.7%
CC50, mM	~3.9%
SI	~12.5%

В eda.ipynb представлены диаграммы размаха для:

- IC50, CC50, SI;
- MolWt, TPSA, MolLogP, qed, NumHDonors, NumHAcceptors.

Агрессивное удаление выбросов не применялось. В drug discovery экстремальные значения могут соответствовать наиболее интересным соединениям: высокоактивным, высокотоксичным или высокоселективным. Удалять такие точки без предметной проверки методологически опасно.

2.5 Корреляции, мультиколлинеарность и связь признаков с целевыми переменными

Молекулярные дескрипторы часто коррелируют друг с другом, поскольку описывают близкие физико-химические свойства. Это ожидаемая мультиколлинеарность:

- линейные модели чувствительны к коррелированным признакам и масштабу;
- Random Forest и Gradient Boosting устойчивее, но importance может распределяться между похожими признаками;
- для будущей интерпретации полезны permutation importance и SHAP.

В eda.ipynb представлена тепловая карта корреляций для целевых переменных и наиболее связанных дескрипторов. Невысокие линейные корреляции объясняют, почему деревья и бустинг в среднем предпочтительнее линейных моделей.

---

3. Анализ утечки целевой переменной

3.1 Почему конечные показатели нельзя использовать как признаки

SI является функцией IC50 и CC50:

SI = CC50 / IC50

Следовательно:

- при прогнозировании SI нельзя использовать IC50 и CC50;
- при прогнозировании IC50 или CC50 нельзя использовать SI;
- в сценарии практического применения безопаснее удалить **все** конечные показатели из X для любой задачи.

Причина: значения IC50, CC50, SI неизвестны до эксперимента. Если они попадают в признаки, модель получает информацию, которая в реальном применении недоступна.

3.2 Найденная утечка

В исходном исследовательском ноутбуке была создана колонка:

df["IC50_log"] = np.log10(df["IC50, mM"] + 1e-8)

Затем эта колонка попадала в X. Для задачи IC50 > median это почти прямое раскрытие ответа: логарифм является монотонным преобразованием IC50, поэтому порог по IC50_log практически восстанавливает бинарную целевую переменную.

3.3 Почему ROC-AUC около 1.0 был некорректен

Старые значения ROC-AUC около 0.99-1.00 возникали не потому, что модели идеально решали химическую задачу, а потому что в признаки попадала производная целевой переменной. Деревья могли найти порог по IC50_log, а Logistic Regression получала почти линейно отделимый признак.

Такая оценка не переносится на новые молекулы, потому что в реальном сценарии IC50_log заранее неизвестен.

3.4 Как устранена утечка

В проекте реализована системная защита:

- в ml_common.py задан список колонок, связанных с целевыми переменными;
- get_target_like_columns() удаляет явные целевые переменные и производные по имени;
- для ic50 и cc50 используется поиск по подстроке;
- для SI используется безопасный список точных имен производных (SI, SI_log, log_SI, SI_bin, SI_class, SI_scaled, target_SI);
- build_feature_matrix() строит матрицу признаков только по молекулярным дескрипторам;

- validate_no_target_like_columns() останавливает обучение, если перед построением модели обнаруживаются признаки утечки;
- устаревшие результаты с утечкой исключены из финальной интерпретации.

---

4. Модели и валидация

Регрессия

Использовались:

- Linear Regression;
- Random Forest Regressor;
- Gradient Boosting Regressor.

Метрики:

- RMSE;
- MAE;
- R2.

Классификация

Использовались:

- Logistic Regression;
- Random Forest Classifier;
- Gradient Boosting Classifier.

Для задач классификации рассчитываются:

- Accuracy;
- Precision;
- Recall;
- F1;
- ROC-AUC;
- PR-AUC.

В финальных таблицах классификации зафиксирован полный набор тестовых метрик после устранения утечки: Accuracy, Precision, Recall, F1, ROC-AUC и PR-AUC. Ниже приведены значения из детальных таблиц результатов по каждой задаче.

---

5. Таблица сравнения лучших моделей по всем 7 задачам

5.1 Задачи регрессии

Задача	Лучшая модель	RMSE	MAE	R2
Регрессия IC50	Random Forest	457.77	240.54	0.3718
Регрессия CC50	Random Forest	455.70	287.39	0.5995
Регрессия SI	Gradient Boosting	1353.61	198.02	0.0878

5.2 Задачи классификации

Задача	Лучшая модель	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
IC50 > median	Random Forest	0.6965	0.6789	0.7400	0.7081	0.7795	0.7763
CC50 > median	Random Forest	0.7015	0.6724	0.7800	0.7222	0.8310	0.8382
SI > median	Random Forest	0.6567	0.6782	0.5900	0.6310	0.6892	0.7010
SI > 8	Random Forest	0.7164	0.6190	0.5417	0.5778	0.7530	0.6856

---

6. Подробные результаты регрессии

6.1 Регрессия IC50

Модель	RMSE	MAE	R2
Random Forest	**457.77**	**240.54**	**0.3718**
Gradient Boosting	463.36	254.44	0.3563
Linear Regression	508.25	267.18	0.2256

Лучшей моделью по RMSE стал Random Forest. Gradient Boosting близок по качеству, но уступает по всем трем тестовым метрикам. Это указывает на нелинейную связь активности с дескрипторами и на ограниченность линейной модели.

6.2 Регрессия CC50

Модель	RMSE	MAE	R2
Random Forest	**455.70**	287.39	**0.5995**
Gradient Boosting	455.71	**283.71**	0.5994
Linear Regression	566.87	390.94	0.3802

CC50 прогнозируется наиболее стабильно: R2 выше, чем для IC50 и SI. Random Forest является лучшей моделью по RMSE, а Gradient Boosting практически равен ему по RMSE и немного лучше по MAE.

6.3 Регрессия SI

Модель	RMSE	MAE	R2
Gradient Boosting	**1353.61**	198.02	**0.0878**
Random Forest	1358.42	**191.19**	0.0813
Linear Regression	1379.37	222.30	0.0528

Регрессия SI остается слабой. Это ожидаемо: SI имеет экстремальный хвост и является отношением двух экспериментальных величин. Для этой задачи более перспективны устойчивые функции потерь, логарифмическое преобразование целевой переменной или переход к пороговой классификации.

---

7. Подробные результаты классификации

7.1 IC50 > median

Модель	ROC-AUC
Random Forest	**0.7795**
Gradient Boosting	0.7756

Модель	ROC-AUC
Logistic Regression	0.7505

После устранения утечки целевой переменной качество стало реалистичным. Random Forest лидирует, но Gradient Boosting близок; это говорит о наличии нелинейной, но нетривиальной связи между дескрипторами и активностью.

7.2 CC50 > median

Модель	ROC-AUC
Random Forest	**0.8310**
Logistic Regression	0.8297
Gradient Boosting	0.8149

Это самая стабильная классификационная задача. Logistic Regression практически не уступает Random Forest (ROC-AUC 0.8297 vs 0.8310), что указывает на выраженный линейный компонент. Random Forest остается лучшей моделью и предпочтительной опорной моделью сравнения, поскольку немного лучше ранжирует объекты и устойчивее к нелинейностям и взаимодействиям.

7.3 SI > median

Модель	ROC-AUC
Random Forest	**0.6892**
Gradient Boosting	0.6730
Logistic Regression	0.6543

Качество умеренное. SI является производным конечным показателем и имеет тяжелый хвост, поэтому связь с молекулярными дескрипторами выражена слабее.

7.4 SI > 8

Модель	ROC-AUC
Random Forest	**0.7530**
Gradient Boosting	0.7375

Модель	ROC-AUC
Logistic Regression	0.6746

Порог SI > 8 практически важен для поиска высокоселективных соединений. Random Forest лучше ранжирует объекты по вероятности высокого SI, а Gradient Boosting является близкой альтернативой.

---

8. Ключевые графики

Все ключевые графики реализованы в eda.ipynb.

8.1 Распределения целевых переменных до и после log1p

Ноутбук содержит:

- гистограммы с KDE для IC50, CC50, SI;
- сравнение исходных распределений и log1p(target);
- таблицу коэффициентов асимметрии до и после log1p.

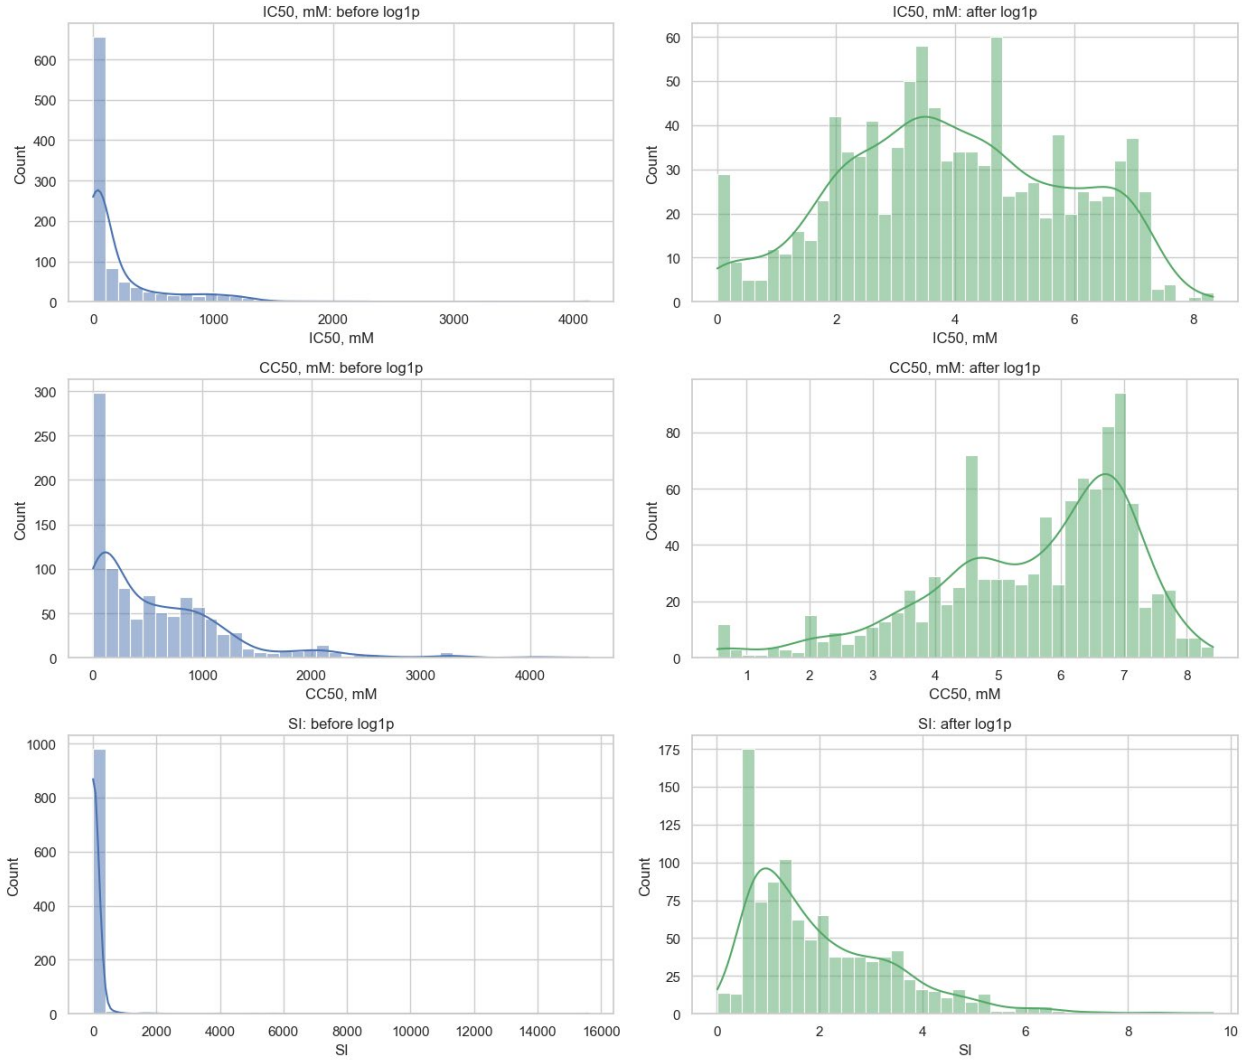

Вывод: log1p снижает асимметрию и визуально сжимает хвосты, но логарифмы целевых переменных не используются как признаки.

8.2 Фактические и предсказанные значения для регрессии

В eda.ipynb представлены диаграммы рассеяния y_true и y_pred с линией y=x для:

- IC50: Random Forest;
- CC50: Random Forest;
- SI: Gradient Boosting.

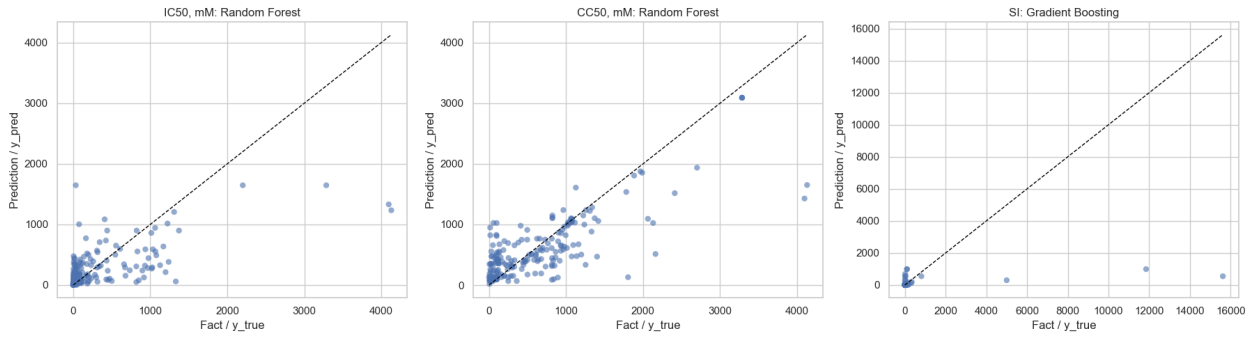

Ожидаемая интерпретация согласована с метриками: CC50 прогнозируется лучше, SI - заметно сложнее.

8.3 Важность признаков

В ноутбуке представлены 15 наиболее важных признаков для:

- Random Forest;
- Gradient Boosting;
- задач IC50 и CC50.

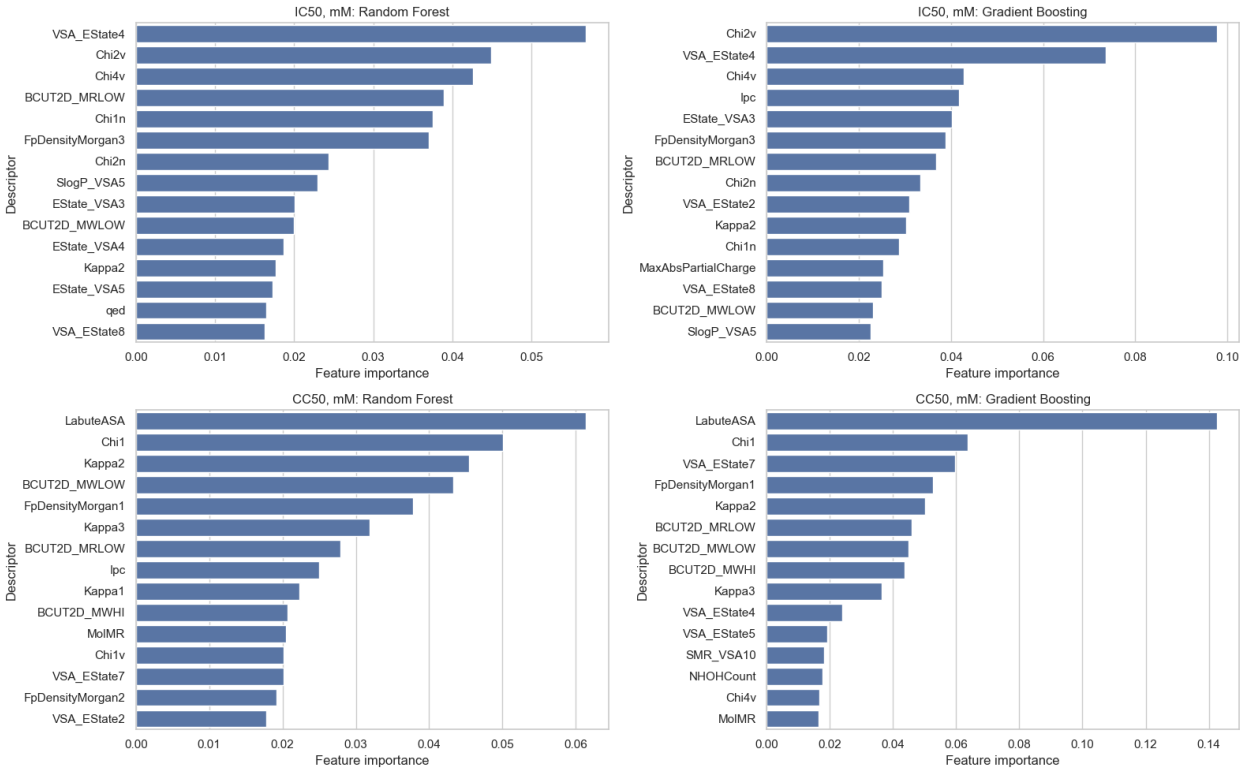

Графики строятся только по матрице молекулярных дескрипторов. Появление среди важных признаков названия, связанного с целевой переменной, является признаком новой утечки данных.

8.4 Матрицы ошибок

В ноутбуке представлены матрицы ошибок для лучших классификационных постановок:

- IC50 > median;
- CC50 > median;
- SI > median;
- SI > 8.

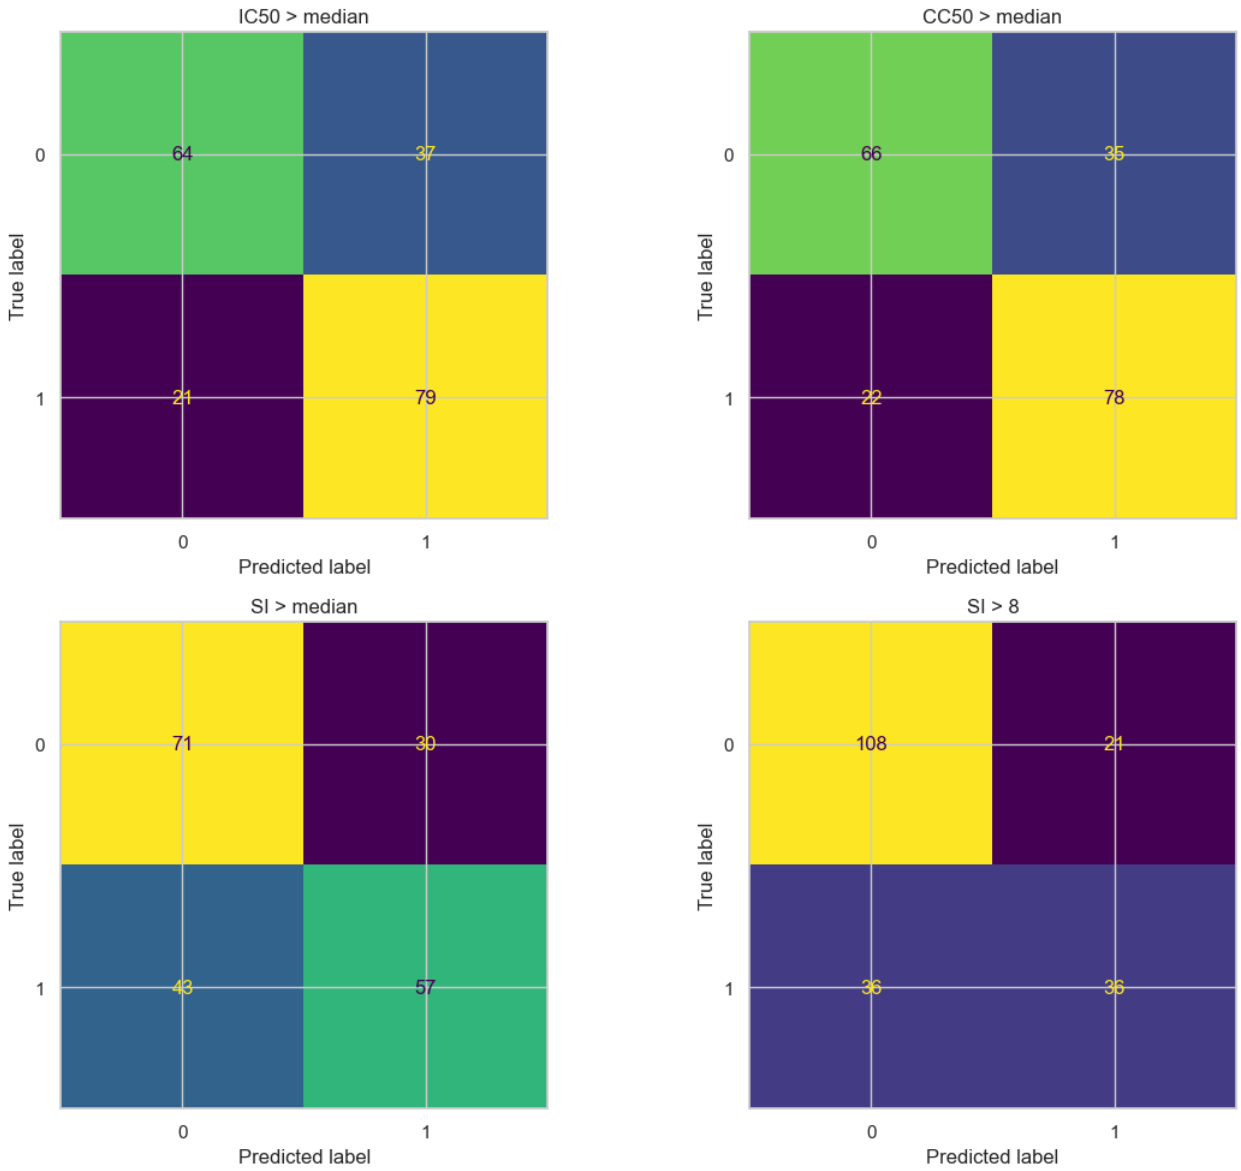

8.5 ROC-кривые и PR-кривые

В ноутбуке представлены ROC- и PR-кривые для задач классификации. PR-кривая особенно важна для SI > 8, где положительный класс менее частый, чем в задачах с порогом по медиане.

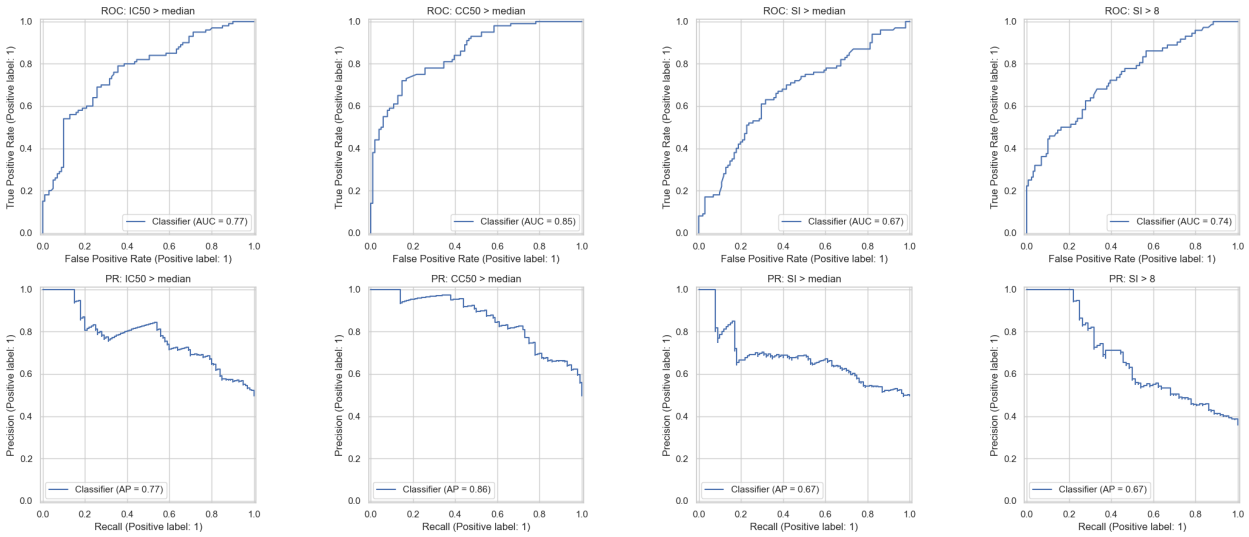

---

9. Переобучение и устойчивость

Разрывы между обучающей и тестовой выборками не являются главным предметом данного отчета, однако по структуре задач можно выделить риски:

- старые ROC-AUC около 0.99-1.00 были не переобучением, а следствием утечки целевой переменной;
- после исключения конечных показателей из признаков ROC-AUC находится в диапазоне 0.6543-0.8310, что является более реалистичной оценкой;
- деревья и бустинг могут переобучаться при слишком большой глубине, поэтому в коде используется перекрестная проверка и случайный поиск гиперпараметров;
- SI наиболее нестабилен из-за тяжелого хвоста.

Для более строгой оценки переобучения в дальнейшем следует отдельно сохранять метрики на обучающей и тестовой выборках для всех моделей.

---

10. Важные признаки

Финальный ноутбук строит диаграммы важности признаков для Random Forest и Gradient Boosting. В отчете не фиксируются конкретные ранги признаков, поскольку они требуют отдельной интерпретации и проверки устойчивости.

Методологический вывод:

- важными должны быть только молекулярные дескрипторы;
- колонки конечных показателей (IC50, CC50, SI) и производные (IC50_log, SI_log и т.д.) не должны попадать в список важных признаков;
- появление такой колонки среди важных признаков является индикатором новой утечки данных.

---

11. Итоговые выводы

Лучшие модели по задачам

Задача	Лучшая модель
Регрессия IC50	Random Forest
Регрессия CC50	Random Forest
Регрессия SI	Gradient Boosting
IC50 > median	Random Forest
CC50 > median	Random Forest
SI > median	Random Forest
SI > 8	Random Forest

Общая интерпретация

1. CC50 - наиболее стабильная задача: и регрессия, и классификация дают лучшие результаты.
2. IC50 имеет умеренно выраженную связь с молекулярными дескрипторами.
3. SI - самая сложная цель из-за тяжелого хвоста и зависимости от двух экспериментальных показателей.
4. Random Forest - лучшая общая опорная модель для практического применения.
5. Gradient Boosting конкурентен для части задач регрессии и близок к Random Forest в части классификации.
6. Logistic Regression полезна как простая модель сравнения, но часто уступает ансамблям деревьев из-за нелинейной структуры данных.

---

12. Что можно улучшить дальше

1. Сохранять разрывы между обучающей и тестовой выборками для всех моделей.
2. Добавить повторную перекрестную проверку и доверительные интервалы.
3. Проверить scaffold split или внешний hold-out.

4. Добавить калибровочные кривые для вероятностей классификации.
5. Использовать SHAP / permutation importance для интерпретации признаков.
6. Рассмотреть LightGBM, XGBoost, CatBoost.
7. Исследовать устойчивые функции потерь и преобразования целевой переменной для регрессии.
8. Выполнять конструирование признаков только на основе молекулярных дескрипторов.

---

13. Финальное заключение

Проект демонстрирует полный цикл классического машинного обучения: разведочный анализ данных, диагностику качества данных, построение моделей регрессии и классификации, обнаружение и устранение утечки целевой переменной, а также осторожную интерпретацию результатов.

Ключевой результат работы - не только сравнение моделей, но и корректировка методологии. Старые почти идеальные значения ROC-AUC были исключены как артефакт утечки целевой переменной. После исправления результаты стали реалистичными и научно корректными: ROC-AUC в задачах классификации находится в диапазоне 0.6543-0.8310, а лучшей общей опорной моделью является Random Forest.